Olist 巴西电商

客户差评归因分析

从流程拆解到多元统计建模的完整分析链路

155 万行真实交易数据 · 99,441 笔订单 · 25 个月

PostgreSQL · Python · Power BI · 统计建模

核心结论

① 「是否迟到」是差评最强预测因子

迟到 53.94% vs 准时 9.18%（5.9 倍）

② 关系是阈值型，不是线性

已超期 53.98%，未超期仅 8.79%–11.16%

③ 运输占全程 74.2%，是瓶颈但不可控

备货仅占 22.3%，却完全可控

④ 超期发货的效应被「迟到」完全中介

控制迟到后 β = −0.0002（p = 0.97）

2026 年 10 月

摘要

本项目基于巴西电商平台 Olist 的公开交易数据（155 万行、99,441 笔订单、25 个月），回答一个具体的业务问题：**什么因素导致客户差评？各因素权重如何？业务该优先改哪一个？**

分析按「沿业务流程拆解 → 单因素归因 → 相关分析 → 多元回归验证」四层递进。先用四段耗时拆解定位瓶颈，再逐个排查地理、卖家、商品、时间四类因素，最后用 OLS、Logistic 回归和随机森林三种方法交叉验证，确保结论不依赖单一模型假设。

五个核心发现

表 五个核心发现与对应证据

#	发现	关键证据
1	「是否迟到」是差评最强预测因子	迟到 53.94% vs 准时 9.18%（5.9 倍） 标准化 β = -0.277，Cohen's d = -1.41，OR = 1.457
2	关系是阈值型（悬崖），不是线性（斜坡）	已超期 53.98%；未超期各档仅 8.79%–11.16% 分段相关：全样本 r=0.256 → 未超期子集 r=0.024
3	运输占全程 74.2%，是瓶颈但不可控	审核 0.43 + 备货 2.81 + 运输 9.33 = 12.56 天 运输由距离决定，平台无法改变
4	超期发货的效应被「迟到」完全中介	单因素 r=-0.106 → 控制迟到后 β=-0.0002（p=0.97） 因果路径：超期发货 → 迟到 → 差评
5	距离的作用被严重高估	相关系数 r=-0.058 → 控制运输时长后 β=+0.064（符号反转） 跨州 Cohen's d 仅 -0.12，可忽略

一个可执行的结论

业务目标应该是「绝不违约」，而不是「盲目提速」

如果关系是线性斜坡，业务应追求"越送越快"；但数据显示是悬崖——

未超期时多等几天几乎不影响评分（8.79%→11.16%），一旦超期就断崖式恶化（→53.98%）。

所以正确的动作是：

- 停止为"数据好看"而收紧预估窗口（2018-08 曾因此让迟到率从 4.5% 涨到 10.4%）
- 建立卖家发货时效考核（9.06% 的超期发货是可控的上游原因）
- 大件品类设独立承诺标准（office_furniture 备货 9.92 天，是均值的 3.5 倍）

项目规模

表 项目规模概览

维度	内容
数据	9 张表 / 1,550,922 行 / 99,441 笔订单 / 96,096 名客户
时间跨度	2016-09 至 2018-10（25 个月）
分析查询	31 条 SQL（7 个部分，逐条验证通过）
统计方法	相关分析（Pearson/Spearman）、效应量、卡方检验、OLS 回归、Logistic 回归、随机森林
建模样本	93,047 条记录、10 维特征，交叉验证 AUC = 0.744
交付物	分析报告 + 6 页 Power BI 仪表盘 + 31 张 SQL 结果图 + 可复现代码

第一章 数据理解与工程实现

1.1 数据集结构

9 张表围绕「订单」这一核心事实表展开。理解表间关系是后续所有分析的前提。

表 9 张表的分工

表名	行数	业务含义	在分析中的作用
orders	99,441	订单主表，含 5 个关键时间戳	★ 计算各环节时长
order_items	112,650	订单明细：商品、单价、运费、发货期限	★ 超期发货判定
order_reviews	99,224	评价：1-5 星评分 + 文字评论	★ 被解释变量
customers	99,441	客户城市、州、邮编	地理因素
sellers	3,095	卖家城市、州、邮编	卖家因素
products	32,951	商品品类、重量、尺寸	商品因素
order_payments	103,886	支付方式、分期数、金额	辅助（证明影响很小）
geolocation	1,000,163	邮编对应经纬度	计算真实距离
category_translation	71	品类葡语→英语	品类可读性

表间关系（外键约束已验证，孤儿记录为 0）

```
customers ──1:N──> orders ──1:N──> order_items <──N:1── products
                      │                    └─────N:1──────────> sellers
                      ├──1:N──> order_payments
                      └──1:N──> order_reviews

products.product_category_name ──N:1──> product_category_translation
```

1.2 两个必须注意的数据陷阱

第 7 部分 数据质量与局限（写报告的"数据说明"部分用） **7.1 关键字段缺失率**

共 4 行 · 耗时 160 ms · 数据源 PostgreSQL 18 / analysis / olist

字段	缺失数	总数	缺失率
商品-品类	610	32951	1.85
评价-评论内容	58247	99224	58.70
订单-审核时间	160	99441	0.16
订单-签收时间	2965	99441	2.98

图 1-1 关键字段缺失率：评论标题缺失 88.3%、评论内容缺失 58.7%

第 7 部分 数据质量与局限（写报告的"数据说明"部分用） **7.4 顾客标识的唯一性（说明为何必须用 customer_unique_id）**

共 1 行 · 耗时 362 ms · 数据源 PostgreSQL 18 / analysis / olist

行数	唯一customer_id	唯一customer_unique_id
99441	99441	96096

图 1-2 顾客标识唯一性：99,441 个 customer_id 各不相同，真实客户仅 96,096 人

陷阱一：customer_id ≠ customer_unique_id

customers 表有 99,441 行，唯一 customer_id 也是 99,441 个——每笔订单都生成新的 customer_id。

真正代表"同一个人"的是 customer_unique_id（96,096 个）。

如果误用 customer_id 计算复购率，会得到 0% 的错误结论。真实复购率约 3.1%。

陷阱二：平均值会骗人

运输时长平均值 9.33 天，但中位数只有 7.10 天，p90 达 18.90 天，最大 205 天。

均值 > 中位数说明分布右偏——平均值被少数极端慢单拉高了。

因此本报告在描述时长时同时给出均值与中位数，并在相关分析中同时计算 Pearson 与 Spearman。

1.3 数据导入与视图设计

使用 psql 的 \copy 命令（客户端读取）导入 9 个 CSV，因为服务端 COPY 需要 pg_read_server_files 超级用户权限。逐表核对行数与源文件一致。

导入命令示例（\copy 是 psql 元命令，需在脚本文件中执行）

```
\copy customers (customer_id, customer_unique_id, customer_zip_code_prefix,
                 customer_city, customer_state)
FROM 'C:/Users/.../olist_customers_dataset.csv'
WITH (FORMAT csv, HEADER true, ENCODING 'UTF8', NULL '');
```

为减少重复 JOIN，建立了 3 个分析视图。其中 v_orders_full 是订单宽表，把订单、客户、金额合计、支付合计、评分合并成一行一单。

1.4 为 BI 构建宽表

直接给 Power BI 提供 9 张表会让建模变得复杂（需手工建 6 条关系、且一对多 JOIN 容易重复计数）。因此专门建了一个订单级宽表 v_pbi_orders，把 7 张表的信息压成一行一单。

v_pbi_orders 视图（订单级宽表，30 个字段）

```
CREATE VIEW olist.v_pbi_orders AS
WITH item_agg AS (                -- ① 明细聚合成一单一行，避免重复计数
    SELECT order_id, sum(price) AS items_total,
           count(*) AS item_count, max(shipping_limit_date) AS ship_limit,
           count(DISTINCT seller_id) AS seller_count,
           min(seller_id) AS main_seller_id, min(product_id) AS main_product_id
    FROM olist.order_items GROUP BY order_id
), ...
SELECT o.order_id, o.order_status,
       -- 过程指标全部预计算，BI 端零 DAX 即可拖拽
       CASE WHEN o.order_delivered_customer_date > o.order_estimated_delivery_date
            THEN 1 ELSE 0 END AS is_late,
       round((EXTRACT(EPOCH FROM (o.order_delivered_carrier_date
              - o.order_approved_at))/86400)::numeric, 2) AS prep_days, ...
FROM olist.orders o
LEFT JOIN item_agg a ON a.order_id = o.order_id   -- ★ LEFT JOIN 保留全部订单
JOIN olist.customers c ON c.customer_id = o.customer_id ...;
```

> **一个必须用 LEFT JOIN 的细节**
>
> 第一版用 INNER JOIN 连商品明细，结果只有 98,666 单——775 笔订单没有商品明细

（603 unavailable、164 canceled 等）被丢掉了，导致差评率从 14.63% 变成 14.13%。

改用 LEFT JOIN 后全量 99,441 单都在，差评率与报告完全一致。

同时把各标记位在"无法判断"时设为 NULL 而非 0，这样 BI 里的 DIVIDE 会自动正确排除。

第二章 五个核心结论

本章是报告主体。每个结论都给出「现象 → 证据 → 业务含义」三段。

2.1 结论一：「是否迟到」是差评最强预测因子

表 迟到 vs 准时的直接对比

指标	准时	迟到	差距
差评率	9.18%	53.94%	5.9 倍
平均评分	4.30	2.61	-1.69 分
样本量	88,649	7,827	—

三种完全不同原理的方法都把「是否迟到」排在第一或第二：

表 五种方法对「是否迟到」的估计

方法	该因素的排名与数值
OLS 标准化系数	排名 1：β = -0.277（t = -56.0，p < 1e-300）
Logistic 优势比	排名 2：OR = 1.457（95% CI 1.428 - 1.486）
随机森林重要性	排名 1：39.60%（第二名的运输为 30.33%）
效应量	Cohen's d = -1.41（极大效应，>0.8 即为大）
卡方检验	x^2 = 11,482.3，Cramér's V = 0.3504（中等关联）

业务含义

客户不是不能等，而是不能接受承诺落空。

满意度管理的重点是"守住承诺"，而不是"盲目提速"。

2.2 结论二：关系是阈值型（悬崖），不是线性（斜坡）

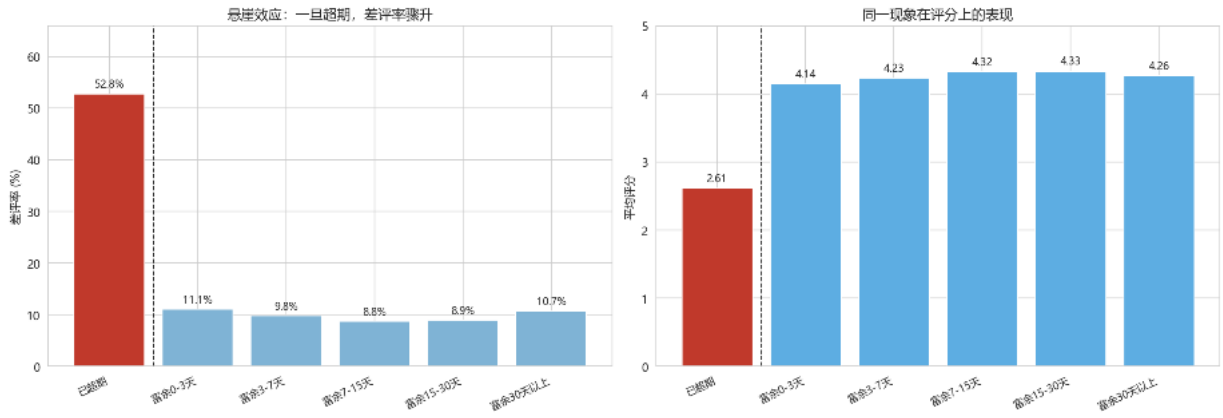


图 2-1 悬崖效应：已超期组差评率 52.8%，未超期各档仅在 8.8%–11.1% 之间持平

表 预估富余分档与差评率

预估富余档	订单数	差评率	平均评分
已超期（负富余）	7,821	52.77%	2.61
富余 0–3 天	4,744	11.16%	4.14
富余 3–7 天	12,586	9.83%	4.23
富余 7–15 天	41,719	8.79%	4.32
富余 15 天以上	29,606	9.14%	4.26

这个结论可以用一个反证来验证：把「已超期」的样本剔除后重新计算相关系数，整体相关性几乎消失。

表 分段相关系数：整体 vs 未超期子集

子集	Pearson r	p 值	解读
全部样本（n = 94,138）	0.2559	≈0	看起来中等相关
仅未超期子集（n = 87,013）	0.0241	1.38e-12	★ 关系几乎消失

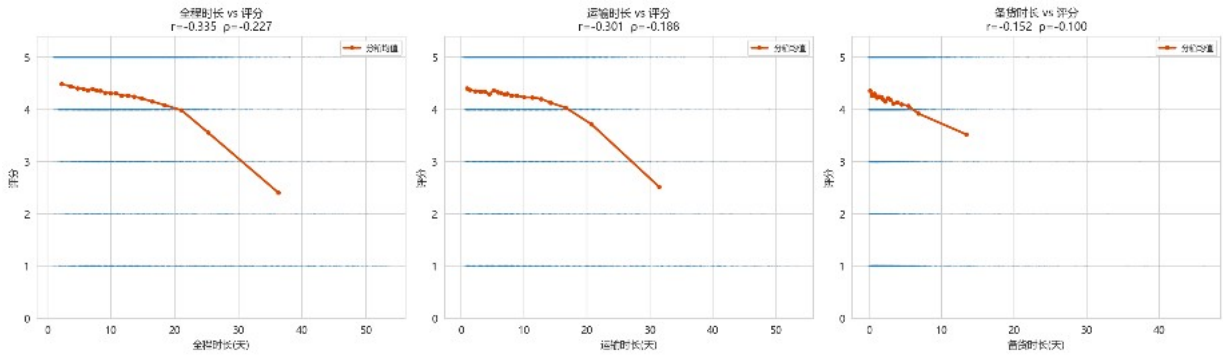


图 2-2 散点与分箱均值曲线：趋势在 20 天左右开始加速下滑，呈明显非线性

这是全项目最重要的统计发现

整体相关系数 r = 0.2559 完全由"已超期"这 7.6% 的样本驱动。

在未超期范围内，富余天数与评分基本无关（r = 0.0241）。

真实关系是「阈值型（悬崖）」，不是「线性型（斜坡）」。

业务含义完全不同：若是斜坡 → 应追求"越送越快"；若是悬崖 → 应追求"绝不违约"。

2.3 结论三：运输是瓶颈但不可控，备货可控

第 1 部分 流程拆解：瓶颈在哪一环节 **1.1 四段耗时拆解 ★ 这一步决定后面查哪里**

结果解读：占比最大的那一段就是瓶颈

共 1 行 · 耗时 157 ms · 数据源 PostgreSQL 18 / analysis / olist

下单到审核_天	审核到发货_天	发货到签收_天	全程_天	样本数
0.43	2.80	9.33	12.56	96461

图 2-3 四段耗时拆解：审核 0.43 天、备货 2.81 天、运输 9.33 天、全程 12.56 天

表 四段耗时、占比与可控性

环节	平均耗时	占全程	可控性	判断
下单 → 审核	0.43 天	3.5%	高	可忽略
审核 → 发货（备货）	2.81 天	22.3%	★ 高	中等，完全可控
发货 → 签收（运输）	9.33 天	74.2%	低（由距离决定）	★ 主要瓶颈

最大的问题 ≠ 最该改的问题

运输占 74.2%，是绝对的流程瓶颈；但它主要由客户与卖家的距离决定，平台改变不了。

备货只占 22.3%，却完全在平台和卖家的控制范围内。

所以改进优先级应该是「可控性 × 影响力」，而不是只看影响力。

特别是 9.06% 的超期发货订单——责任清晰、可考核、可改进。

2.4 结论四：距离的作用被严重高估

表 距离效应在单因素与多因素下的对比

分析方式	距离与评分的关系	解读
Pearson 相关	r = -0.0580	弱负相关，看似"越远越不满"
Cohen's d（跨州 vs 同州）	-0.12	效应量可忽略
★ 多元回归（控制运输时长）	β = +0.0636（p < 1e-300）	符号反转为正
★ Logit（控制运输时长）	OR = 0.848（p < 1e-300）	距离越远，差评几率反而更低

为什么会符号反转？（典型抑制效应）

距离与运输时长高度相关（r = 0.44）。距离远 → 运输慢 → 评分低，这是距离的"间接负效应"。

但在多元模型中，控制住"运输时长"后，问的就变成「同等运输时长下，远近还有什么差别」

——

结果发现远距离订单评分反而略高。

可能原因：偏远地区客户预期更低、平台预估窗口更宽松。

方法论意义：不能用单因素相关系数断言"距离导致不满"。

2.5 结论五：品类差评分两类，处置方式完全不同

把「差评率」和「平均备货天数」并排看，高差评品类会分成两种截然不同的类型：

表 高差评品类的两种类型

品类	订单数	差评率	平均备货	类型	处置方向
office_furniture	1,267	22.51%	9.92 天	物流型	大件品类设独立承诺标准
audio	347	21.51%	2.51 天	★ 商品型	查商品描述、质检、包装

fixed_telephony	215	18.87%	3.41 天	商品型	同上
home_confort	388	18.65%	2.3 天	商品型	同上
bed_bath_table	9,297	16.32%	2.71 天	混合	需进一步拆分

这条洞察比「差评率排行」有价值得多

office_furniture 高差评可以用备货慢解释（9.92 天，全国均值 2.81 的 3.5 倍）——改物流有效。

但 audio 差评率 21.51%，备货只有 2.51 天（比均值还快），说明差评来自商品本身——描述不符、质量问题、到手损坏，靠改物流完全无效。

同样是"高差评品类"，根因不同，处置方式完全不同。

2.6 五因素汇总对比

表 五因素对差评率的影响排序

排名	因素	高分组差评率	低分组差评率	差距
1	是否迟到	53.94%（迟到）	9.18%（准时）	+44.8 pp
2	运输时长	48.01%（21 天+）	8.46%（3 天内）	+39.6 pp
3	备货时长	41.56%（14 天+）	9.84%（1 天内）	+31.7 pp
4	超期发货	23.69%（超期）	11.68%（按期）	+12.0 pp
5	是否跨州	14.07%（跨州）	10.43%（同州）	+3.6 pp

第三章　统计与建模验证

第二章的结论全部经过统计检验和多元建模验证。本章说明验证过程与两处颠覆性发现。

3.1　相关分析：Pearson 与 Spearman

同时计算两种相关系数：Pearson 衡量线性关系，Spearman 衡量单调关系。本数据多个变量偏度绝对值大于 1（审核时长 4.48、运费 12.90），分布明显右偏，此时 Pearson 会失效，必须对照 Spearman。

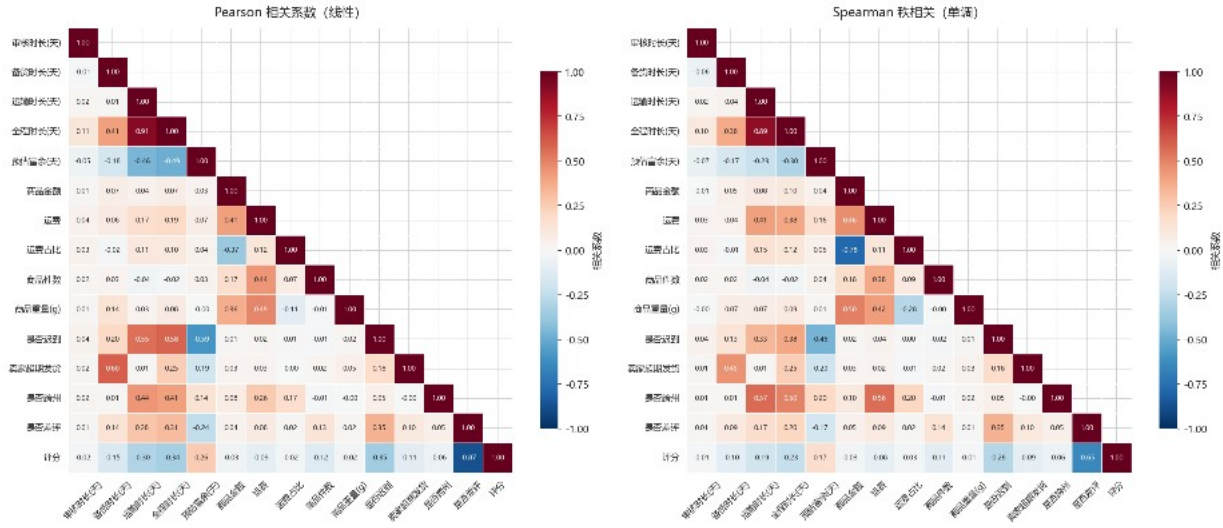


图 3-1　相关系数热力图（左：Pearson 线性；右：Spearman 单调）

表　各因素与「评分」的相关系数（n = 93,526）

因素	Pearson r	Spearman ρ	强度判断
是否迟到	−0.3514	−0.2823	强负相关
全程时长	−0.3351	−0.2266	强负相关
运输时长	−0.3015	−0.1877	中等负相关
预估富余	+0.2559	+0.1684	中等正相关
备货时长	−0.1515	−0.1004	弱负相关
卖家超期发货	−0.1058	−0.0924	弱负相关
是否跨州	−0.0580	−0.0557	极弱

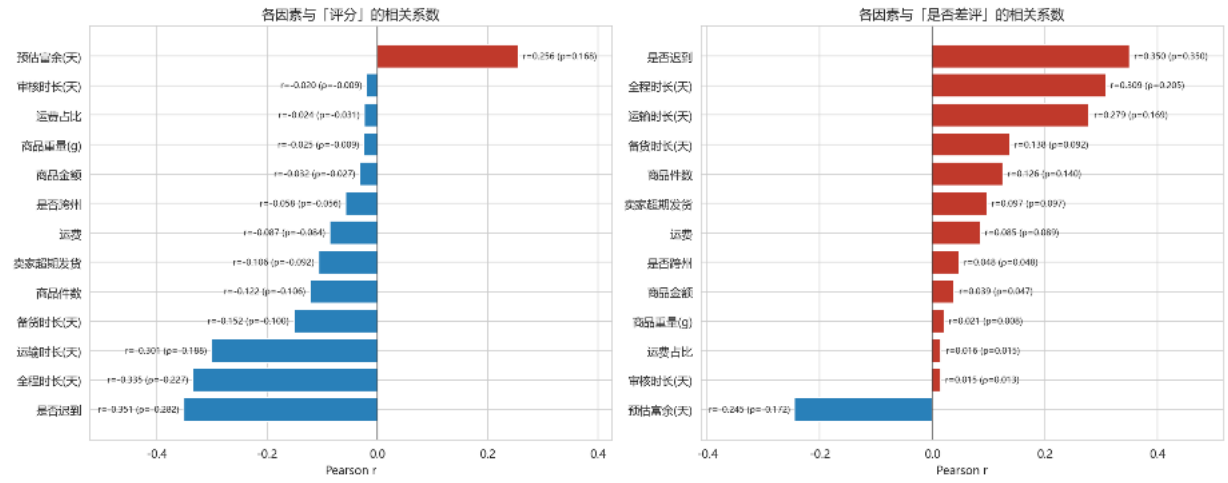


图 3-2 各因素与「评分」/「是否差评」的相关强度对比

3.2 效应量：p 值之外的另一半

p 值只回答"有没有差异"，效应量回答"差异有多大"。本项目样本达 9.3 万，几乎所有 p 值都趋近于 0，因此必须同时报告效应量。

表 组间差异的效应量

分组变量	Cohen's d	判读	说明
是否迟到	−1.41	★ 极大效应	迟到组评分分布整体左移 1.41 个标准差
卖家超期发货	−0.37	小–中效应	单因素看有影响，但多因素下消失
是否跨州	−0.12	可忽略	远低于 0.2 的"小效应"门槛

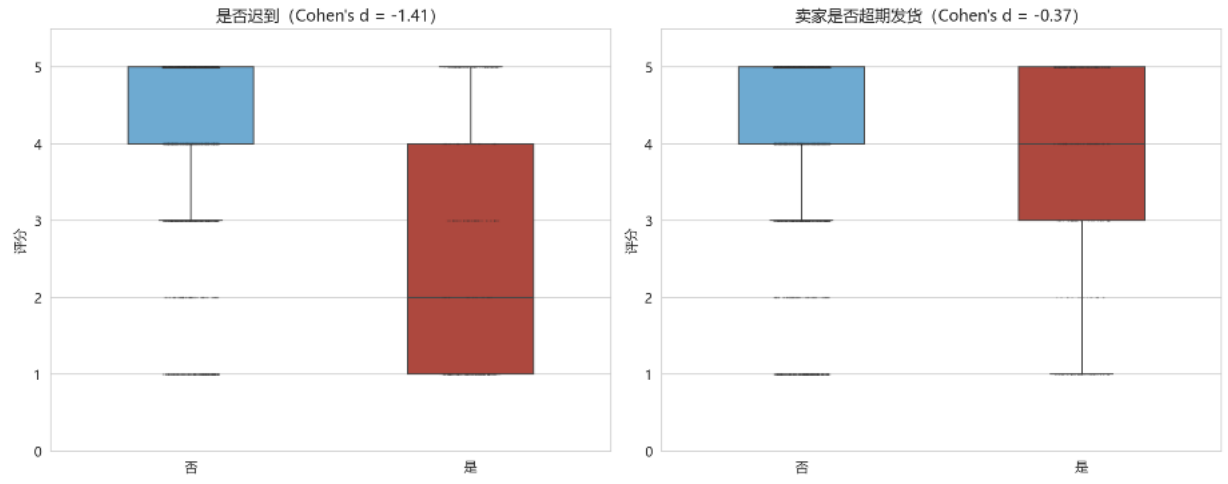


图 3-3 迟到 / 超期发货两组的评分箱线图（标题标注 Cohen's d）

大样本陷阱（容易被追问）

样本量越大，p 值越容易变小。本项目几乎所有 p 值都 < 1e-300，

连相关系数只有 0.02 的变量都"显著"。

所以不能只看 p 值，必须同时看效应大小。

例如"是否跨州"的 p 值也 < 0.001，但 d 只有 -0.12，实际可忽略。

3.3 多元线性回归（OLS）

表 OLS 模型整体拟合情况

整体指标	数值	含义
样本量 N	93,047	—
R^2	0.1695	模型解释了 16.95% 的评分方差
调整 R^2	0.1694	几乎无衰减，无过拟合
F 统计量	1,898.8	整体模型高度显著
VIF	全部 < 3	无多重共线性问题

表 OLS 标准化系数（因变量：评分）

排名	变量	标准化 β	t 值	p 值	显著性
1	是否迟到	-0.2771	-56.0	<1e-300	***
2	运输时长(天)	-0.2749	-49.1	<1e-300	***
3	商品件数	-0.1642	-40.4	<1e-300	***
4	备货时长(天)	-0.1310	-27.2	<1e-300	***
5	距离(对数 km)	+0.0636	10.5	<1e-300	***
6	是否跨州	+0.0151	2.6	0.0088	**
7	重量(对数 g)	+0.0123	2.7	0.0063	**
8	金额(对数)	-0.0063	-1.0	0.3042	ns
9	运费占比	-0.0041	-0.7	0.4564	ns
10	卖家超期发货	-0.0002	-0.0	0.9730	ns

3.4 逻辑回归：优势比

表 Logit 模型整体情况

整体指标	数值
McFadden 伪 R^2	0.1518
LR 统计量	10,629.7（df = 10，p < 1e-300）
基准差评率	12.47%

表 Logit 优势比（每增加 1 个标准差，差评几率的变化倍数）

变量	OR	95% 置信区间	p 值
运输时长(天)	1.603	[1.562, 1.646]	<1e-300
是否迟到	1.457	[1.428, 1.486]	<1e-300
商品件数	1.351	[1.327, 1.375]	<1e-300
备货时长(天)	1.252	[1.225, 1.280]	<1e-300
距离(对数 km)	0.848	[0.820, 0.878]	<1e-300
金额(对数)	1.089	[1.054, 1.125]	2.81e-07
重量(对数 g)	0.947	[0.924, 0.971]	1.67e-05
运费占比	1.034	[1.008, 1.062]	0.0108
卖家超期发货	1.013	[0.990, 1.037]	0.2756
是否跨州	0.996	[0.964, 1.030]	0.8237

3.5 随机森林对照

表 随机森林特征重要性（5 折交叉验证 AUC = 0.744）

变量	重要性	占比
是否迟到	0.3960	39.60%
运输时长(天)	0.3033	30.33%
商品件数	0.1003	10.03%
备货时长(天)	0.0710	7.10%
距离(对数 km)	0.0408	4.08%
其余 5 个变量合计	0.0986	9.86%

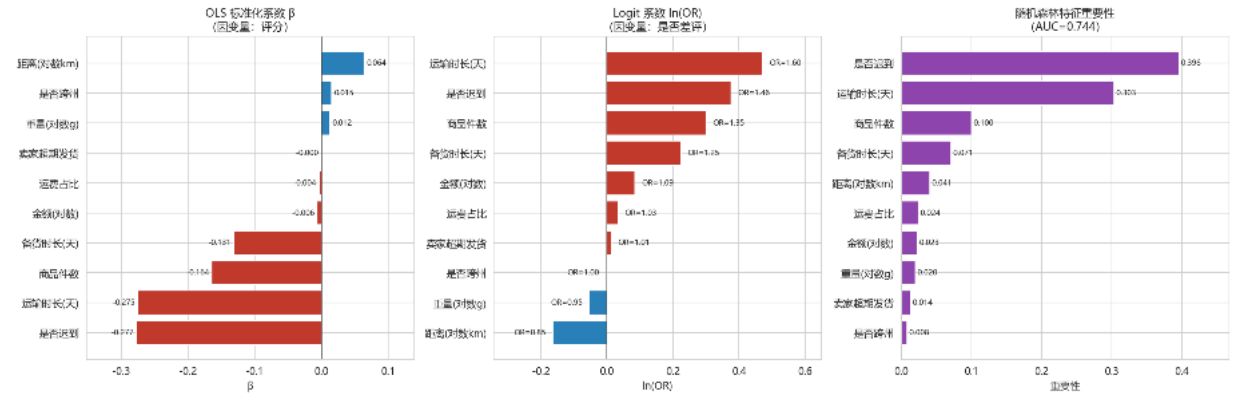


图 3-4 三种方法的系数/重要性对比：结论高度一致

3.6 两处颠覆单因素结论的发现

3.6.1 发现一：超期发货的效应被「迟到」完全中介

表 超期发货在单因素与多因素下的对比

分析方式	结果	结论
单因素相关	r = -0.1058（p ≈ 0）	看似显著
单因素分组	评分 3.70 vs 4.20	看起来影响很大
★ 多元回归（控制迟到）	β = -0.0002，p = 0.973	直接效应几乎为零
★ Logit（控制迟到）	OR = 1.013，p = 0.276	优势比不显著

因果路径：超期发货 → 迟到 → 差评

客户并不知道卖家有没有超期（那是平台内部指标），客户只感受得到"有没有按时收到"。

所以一旦控制住"是否迟到"，超期发货就失去了独立解释力。

业务含义：考核卖家发货时效仍有意义（它是上游原因），

但真正的 KPI 应该是"准时送达率"，而不是"按时发货率"。

3.6.2 发现二：距离的符号反转（抑制效应）

见第二章 2.4 节。这是典型的抑制效应，也是"只看相关系数会出错"的最好例证。

3.7 稳健性检验

表 分年度稳健性检验（标准化系数）

子样本	N	迟到 β	距离 β	超期 β	R^2
2017 年	42,331	−0.2528	+0.0612	−0.0051	0.1408
2018 年	50,456	−0.2937	+0.0626	+0.0041	0.1931
全样本	93,047	−0.2771	+0.0636	−0.0002	0.1695

三个关键结论在两年间完全一致，说明不是特定年份的偶然现象。

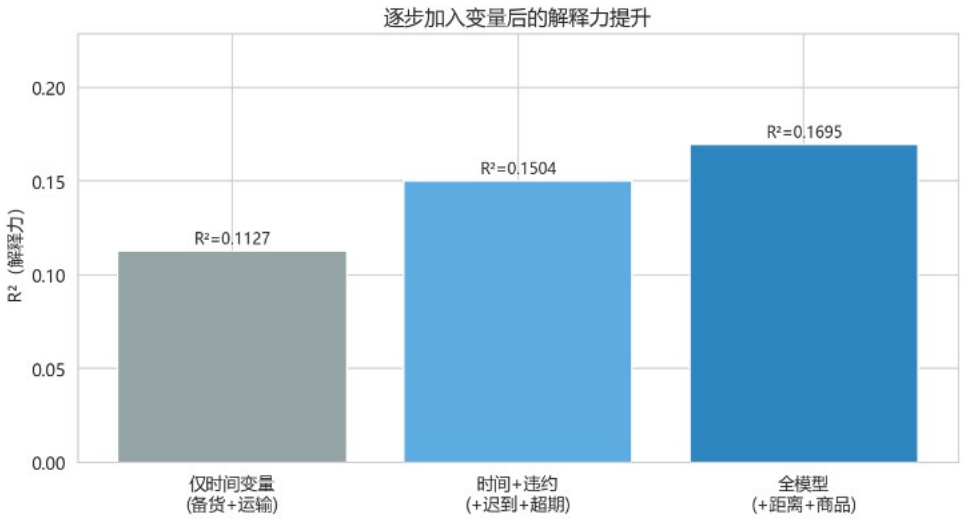


图 3-5 逐步加入变量后的解释力：仅时间变量 R^2=0.11 → 加入违约 0.16 → 全模型 0.17

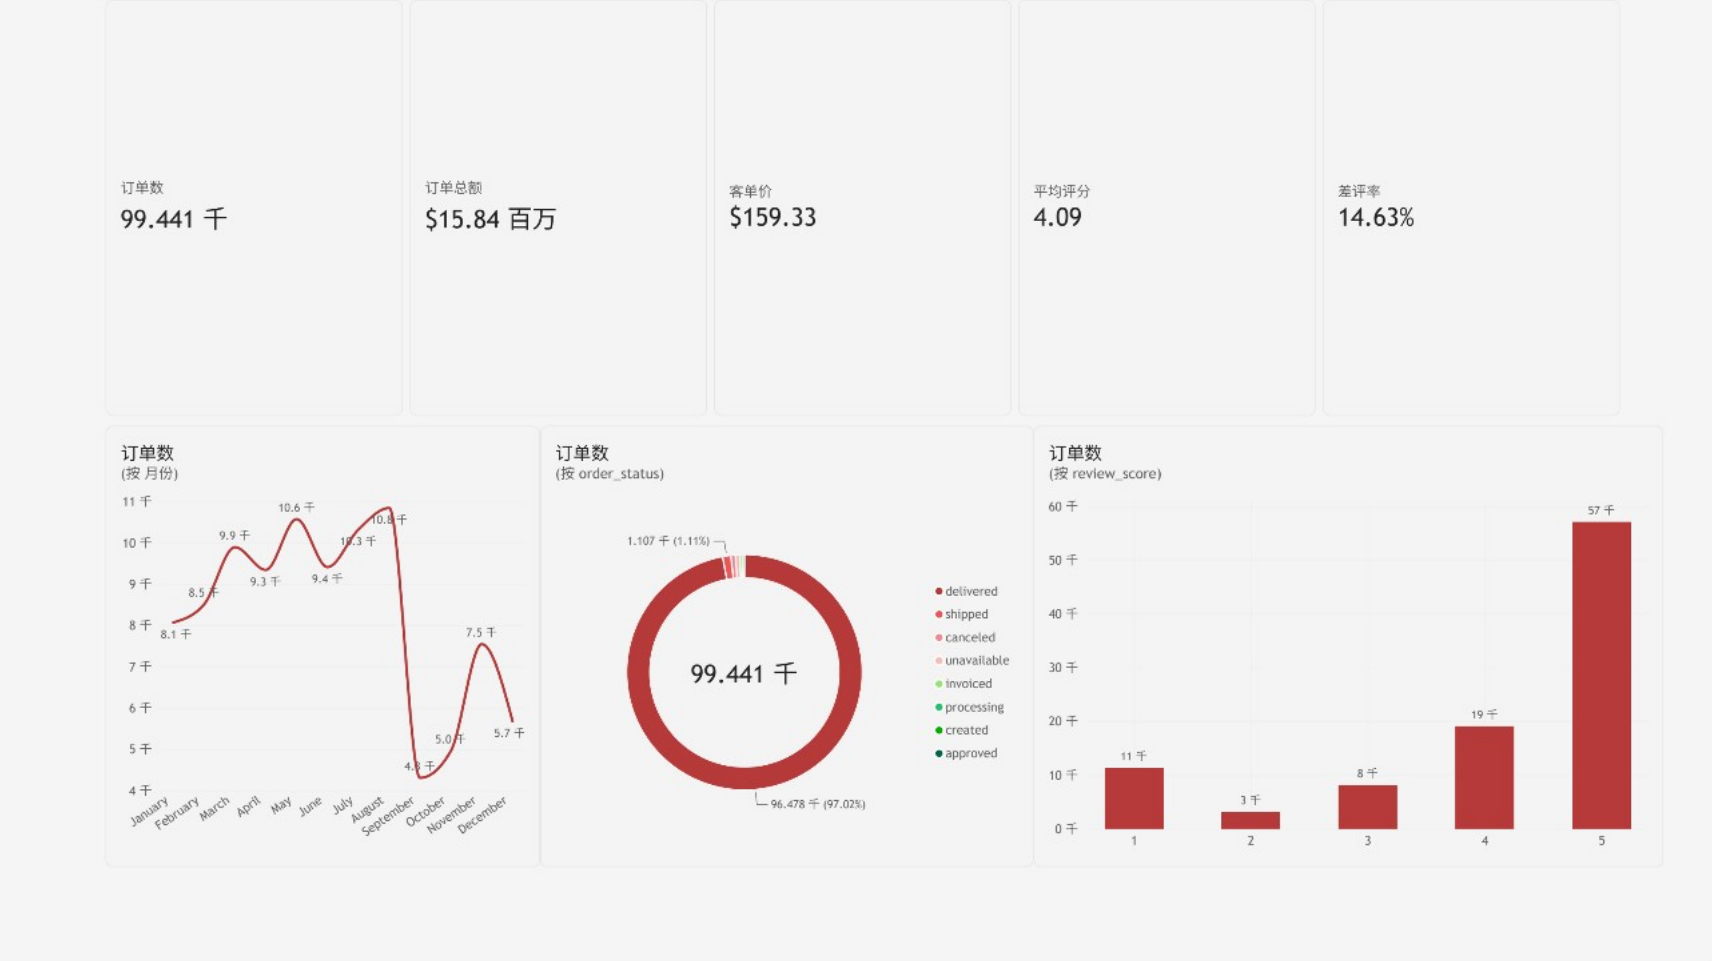
第四章 交互式仪表盘（Power BI）

为让结论可以被业务方自助探索，用 Power BI 构建了 6 页交互式仪表盘，数据源是从 PostgreSQL 直接连接的订单级宽表 v_pbi_orders（99,441 行）。

表 仪表盘页面结构

页面	内容	核心图表
P1 经营总览	5 项核心 KPI + 趋势 + 分布	多行卡、折线图、环形图、柱形图
P2 差评归因	★ 六因素对差评率的对比	6 个簇状柱形图 + 结论文本框
P3 流程拆解	三段耗时占比 + 月度迟到率	环形图、明细表、折线图
P4 地域分析	各州订单量/迟到率/差评率	3 个条形图 + 气泡图
P5 品类分析	品类销售额/差评率/备货天数	3 个条形图 + 矩阵表
P6 数据说明	口径定义与局限	文本框

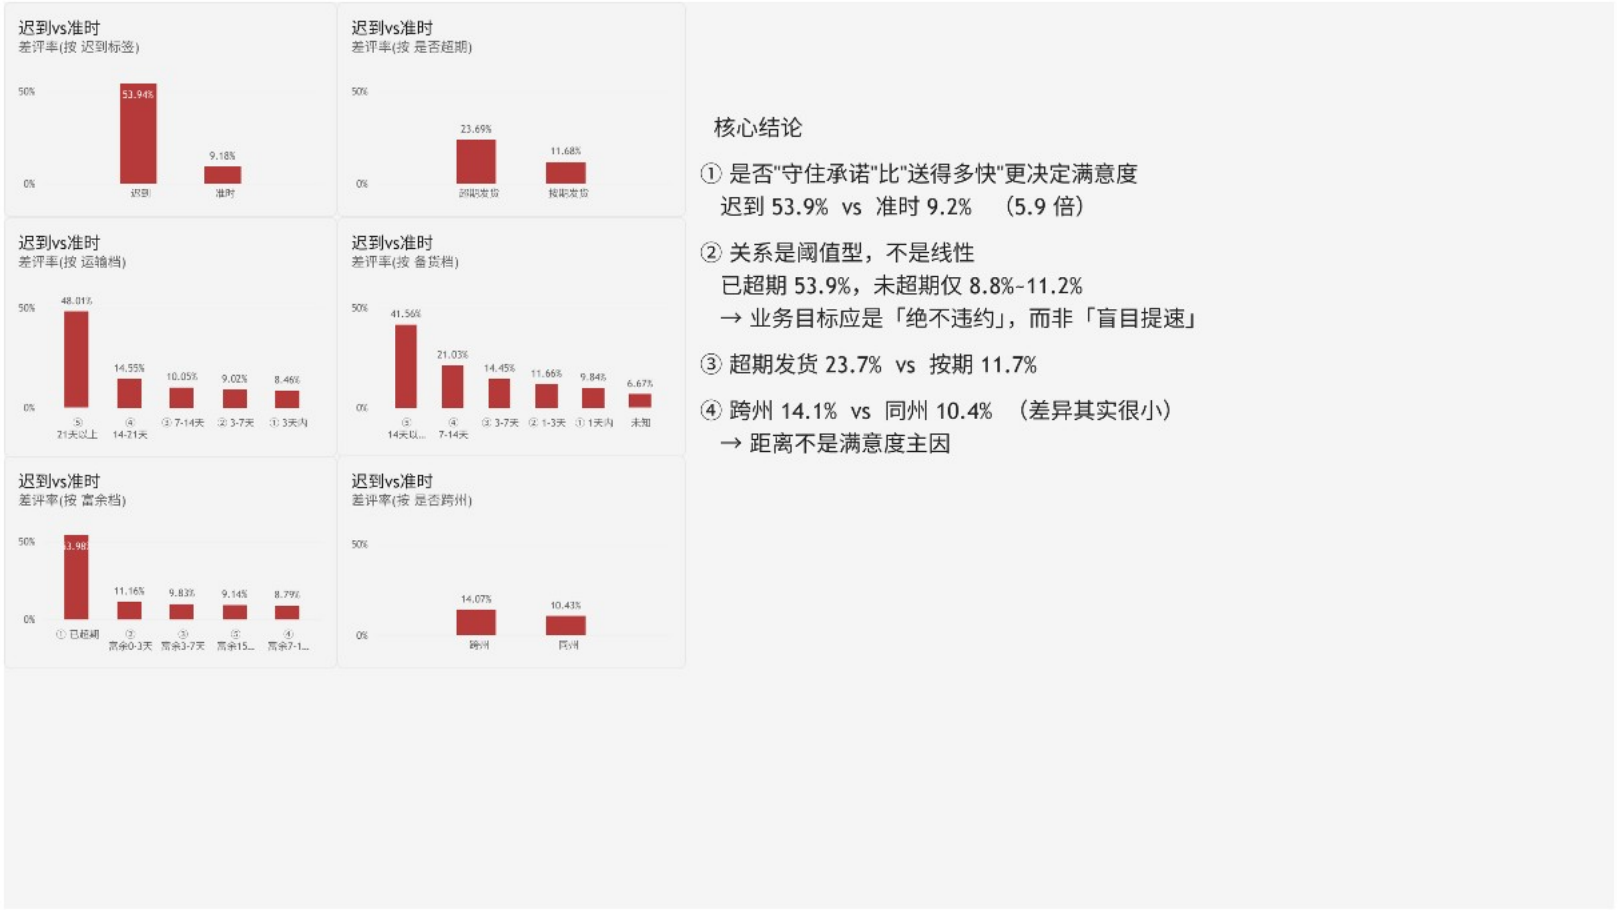
4.1 P1 经营总览



仪表盘 P1 经营总览：99,441 单 / R$ 15.84M / 客单价 R$ 159.33 / 评分 4.09 / 差评率 14.63%

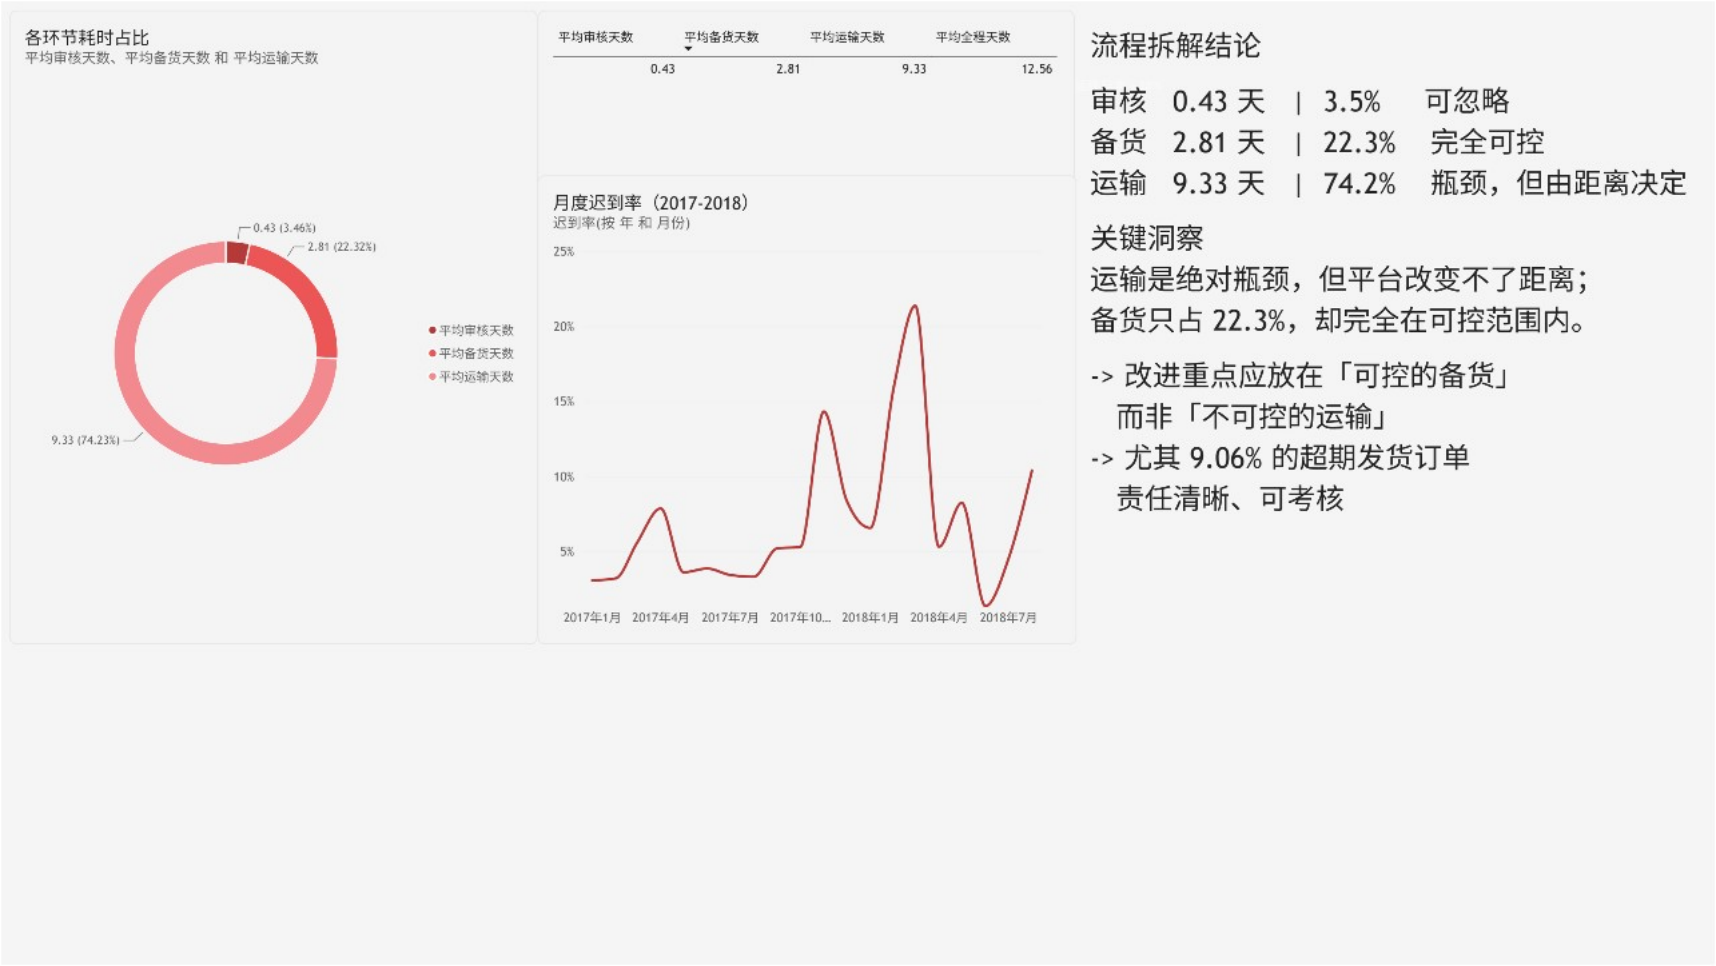
4.2 P2 差评归因（核心页）

这一页是整份报告核心结论的可视化：六个因素分别作为一个柱形图，Y 轴统一为差评率、统一量程 0–60%，方便横向对比。



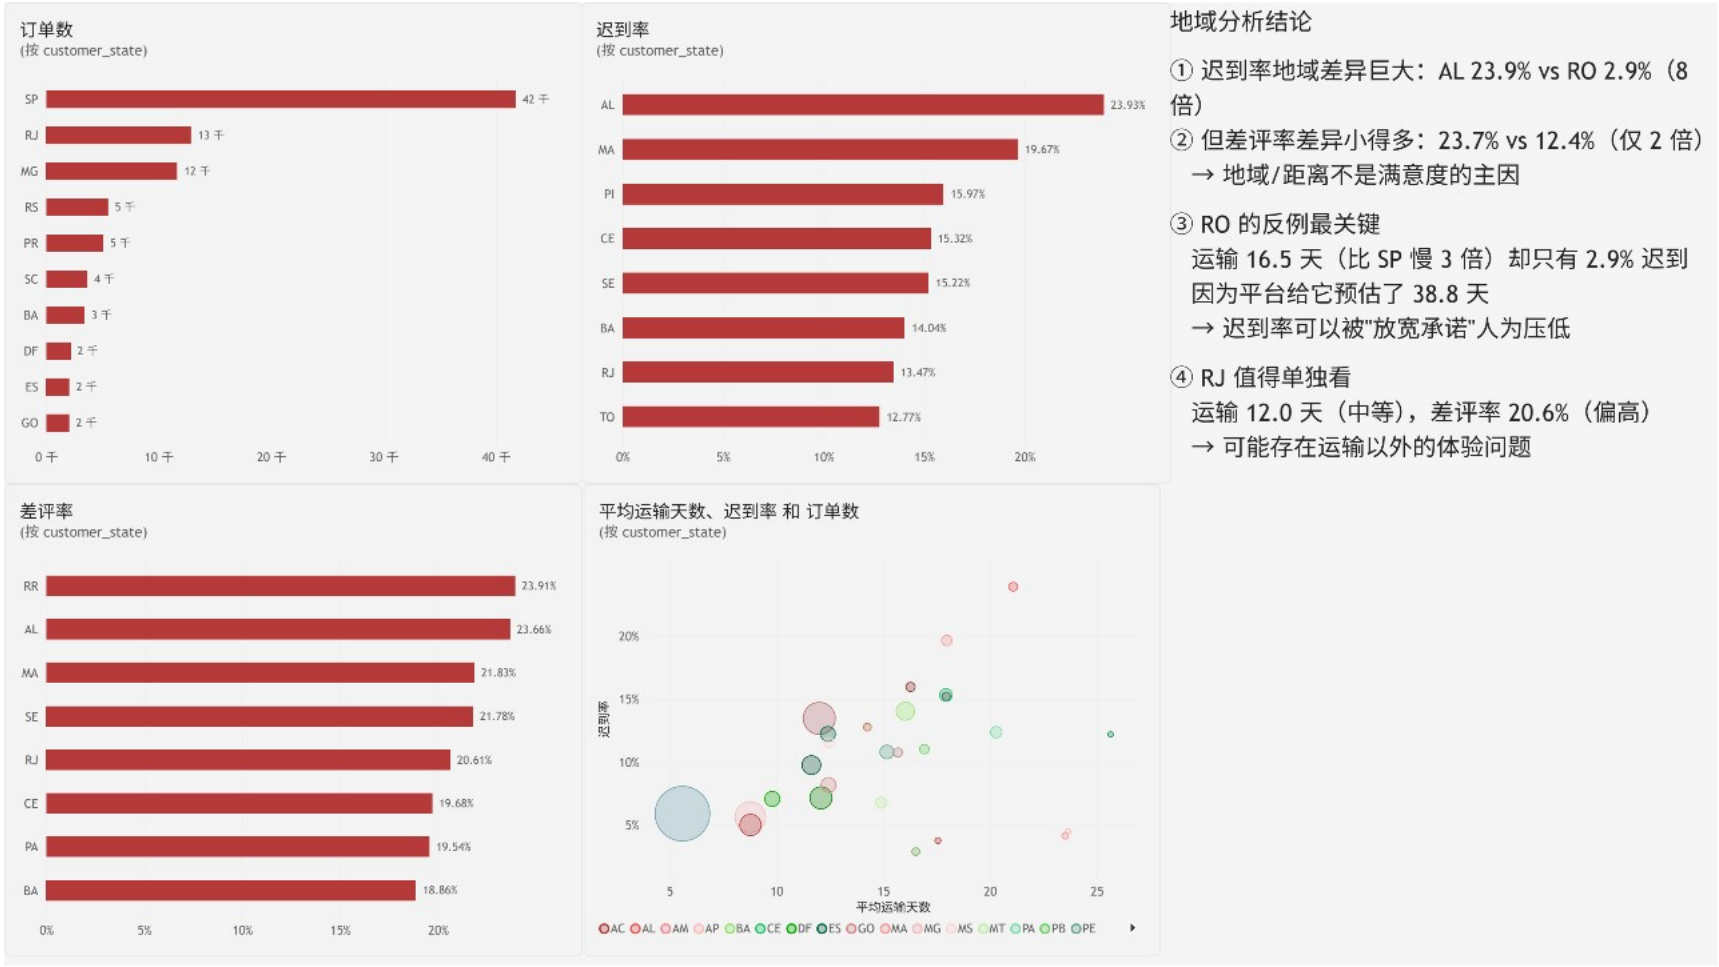
仪表盘 P2 差评归因：迟到 53.94% vs 准时 9.18%；超期 23.69% vs 按期 11.68%；跨州 14.07% vs 同州 10.43%

4.3 P3 流程拆解



仪表盘 P3 流程拆解：运输占 74.23%，是绝对瓶颈；月度迟到率在 2018-03 达到 21.4%

4.4 P4 地域分析



仪表盘 P4 地域分析：AL 迟到率 23.93% 最高，RO 仅 2.9%；气泡图展示"运输天数 × 迟到率 × 订单量"

4.5 P5 品类分析



仪表盘 P5 品类分析：office_furniture 差评 22.51% 且备货 9.92 天（物流型）；audio 差评 21.51% 但备货仅 2.51 天（商品型）

4.6 P6 数据说明

数据来源
Olist 巴西电商公开数据集（Kaggle，CC BY-NC-SA 4.0）
时间范围：2016-09 – 2018-10
规模：9 张表 / 1,550,922 行 / 99,441 笔订单 / 96,096 名客户

指标口径
· 差评　　评分 ≤ 2 星
· 迟到　　签收时间 > 平台预估送达时间
· 超期发货　交给物流时间 > 卖家承诺发货期限（shipping_limit_date）
· 预估富余　预估送达时间 − 实际签收时间（负数=已超期）
· 全程时长　签收时间 − 下单时间
· 三段拆分　审核（下单→审核）/ 备货（审核→交物流）/ 运输（交物流→签收）

分析方法
流程拆解 → 单因素归因 → 相关分析（Pearson/Spearman + 效应量）
→ 多元回归控制混杂（OLS / Logistic / 随机森林交叉验证）

已知局限
· 订单只有一个签收时间戳，分批发货场景指标失真
· 模型 R^2 = 0.17，只适合群体归因，不适合预测个体客户
· 未做随机对照实验，结论为"强相关 + 合理机制"，非严格因果
· main_category 取订单首个商品，约 1-2% 订单归类不精确
· 缺失数据：评论标题 88.3%、评论内容 58.7%（故未做文本情感分析）

修正记录
初版结论认为"卖家超期发货是最大痛点"（单因素 r = -0.106）。
补做多元回归后发现：控制"是否迟到"后其直接效应几乎为零（β = -0.0002, p = 0.97），
属于完全中介效应（超期发货 → 迟到 → 差评）。
这个修正比原结论更有价值。

仪表盘 P6 数据说明：数据来源、指标口径、分析方法、已知局限与修正记录

第五章 业务建议

5.1 三条核心建议

表 按优先级排列的业务建议

优先级	措施	数据依据	预期效果	成本
P0	停止为"数据好看"而收紧预估窗口	2018-08 预估压至 15.2 天，实际送更快（7.7 天）但迟到率从 4.5% 涨到 10.4%	迟到率可降 5–8 pp	极低（改参数）
P0	建立卖家发货时效考核，超期扣分/降权	9.06% 超期发货；超期单差评率 23.69%（基线 14.63%）	超期率降到 5%，可减少约 1/3 相关差评	低（定规则）
P1	大件/家具品类设独立承诺标准	office_furniture 备货 9.92 天（均值 3.5 倍），差评 22.51%	避免卖家被误判，减少品类性差评	低
P1	旺季（黑五/圣诞）提前扩容运力	2017-11 订单 +63%，迟到率 5.3% → 14.3%；2018-03 迟到 21.4%	旺季迟到率减半	中
P2	聚焦 Top 卖家治理（按影响面排序）	单一卖家贡献 8,623 天超额延误（是第二名的 4.5 倍）	集中资源，ROI 最高	低
P2	多卖家订单体验专项	2 卖家订单差评率 46.34%（全国 12.5%）	该场景仅占 1.3%，但体验极差	中
—	不建议盲目在偏远州投运力	距离净效应 +0.064（控制运输时长后为正），d = -0.12	投入产出比低	—

5.2 指标体系建议

表 建议的指标体系

层级	指标	建议目标	说明
北极星	差评率（1-2 星占比）	14.63% → 10% 以内	直接反映客户满意度
过程	准时送达率	92.28% → 96%	★ 最重要，对应最强因素
过程	卖家超期发货率	9.06% → 5% 以内	迟到的上游原因，可考

			核
过程	平均备货天数	2.81 → 2.2 天	完全可控
预警	预估收紧幅度 ÷ 实际提速幅度	比值 ≤ 1	★ 防止为数据好看而收紧承诺
分群	各州 / 各品类准时率	差异化目标	避免全国平均掩盖结构问题

特别说明「预警指标」：2018 年 8 月的数据显示，平台把预估从 19.7 天压到 15.2 天，实际配送反而更快了（9.0 → 7.7 天），但迟到率从 4.5% 涨到 10.4%。如果不监控「承诺 vs 实际的相对变化」，这类问题会被误判为「物流变差」。

5.3 落地路线图

表 三阶段落地路线图

阶段	时间	动作	预期收益
第一阶段 快速见效	0–1 个月	① 上线卖家超期发货考核 ② 冻结预估窗口收紧操作 ③ 建立差评率周报	超期率 -2 pp，迟到率 -3 pp
第二阶段 结构优化	1–3 个月	① 按影响面排序治理 Top 50 卖家 ② 大件品类独立承诺标准 ③ 多卖家订单体验排查	差评率 -2 pp
第三阶段 长期建设	3–6 个月	① 旺季运力弹性预案 ② 分州差异化承诺策略 ③ 远距离订单主动通知机制	旺季迟到率减半

第六章 局限与修正记录

一份诚实的分析必须说明自己没做到什么、哪里可能出错。这一章也是本项目最贴近真实工作的部分。

6.1 数据本身的局限

表 数据局限性清单

局限	具体影响	本报告的处理
订单只有一个签收时间戳	分批发货时无法反映最晚送达，多卖家订单指标失真	不采信该指标，并说明原因
缺少物流商字段	无法归因到具体承运方	作为局限说明
评论缺失率高（标题 88.3%、内容 58.7%）	无法做文本情感分析	只使用评分
4 个月份数据不完整	月度趋势首尾失真	分析时剔除（HAVING 门槛）
23 条负值时间戳	污染时长计算	剔除（占 0.02%）
geolocation 重复采样	100 万行仅 19,015 个邮编	按邮编聚合取均值

6.2 分析方法的局限

- 因果推断有限：虽然具备时间先后、剂量反应和合理机制，但缺乏随机对照实验，严格意义上只能说"强相关 + 合理机制"，不能断言因果。
- R^2 仅 0.17：评分为主观打分，大量未观测因素（商品质量、客服态度、包装）无法进入模型。模型适合做群体归因，不适合预测个体。
- 未纳入卖家/品类固定效应：本报告用距离和件数等变量控制，但没有为每个卖家、每个品类加虚拟变量。加入后 R^2 会提升，但会牺牲可解释性。
- main_category 取订单首个商品：约 1–2% 的订单品类归类不精确。

6.3 ★ 修正记录：一个被推翻的结论

这是本项目最有价值的一段，因为它体现了「分析过程中如何自我纠错」。

表 结论的修正过程

阶段	当时的结论	依据
初版（单因素）	"卖家超期发货是最大痛点"	相关系数 r = -0.106，评分 3.70 vs 4.20
补做多元回归后	"超期发货的效应被迟到完全中介"	控制迟到后 β = -0.0002（p = 0.97），OR = 1.013（p = 0.28）
最终结论	"真正的 KPI 是准时送达率，而非按时发货率"	因果路径：超期发货 → 迟到 → 差评

这个修正为什么比原结论更有价值

如果报告停在"超期发货是最大痛点"，后续建议就会写成"考核卖家发货率"，
而客户真正在意的"是否按时收到"反而被忽略。

补做多元回归后才发现：超期发货是"原因的原因"，真正的直接原因是迟到。
这直接改变了建议的方向——从"考核发货率"改为"考核准时送达率 + 管住预估窗口"。

6.4 如果重做一次

- 一开始就把「差评率」定为核心因变量，而不是中途从「配送时长」切换——前期有一半精力花在过程指标上，最后还要换算才能比较权重。
- 更早做多元建模。做完所有单因素分析后才补回归，才发现两个结论需要修正。如果先建模再细查，能少走弯路。
- 对多卖家订单的异常，应该第一时间查数据字典而不是先做统计——这类「指标失效」问题，业务理解比统计方法更有效。
- 把清洗阈值、随机种子等参数外置成配置，便于复现和敏感性分析。

第七章 技术实现与复现

7.1 技术栈

表 技术栈

层次	工具	用途
数据存储	PostgreSQL 18	导入 9 张 CSV，建索引、外键、视图
数据查询	SQL（psql / VS Code）	31 条分析查询，含 CTE、窗口函数、FILTER 聚合
统计分析	Python 3.11（pandas / SciPy / NumPy）	数据清洗、相关分析、手写 OLS 推断
机器学习	scikit-learn	Logistic 回归、随机森林、交叉验证
可视化	Matplotlib / Seaborn	8 张统计图表
BI 报表	Power BI Desktop	6 页交互式仪表盘
文档	python-docx	自动生成报告（便于数据更新后重跑）

7.2 仓库结构

推荐的项目结构

```
olist-review-attribution/
├── README.md                    # 项目说明与核心结论
├── sql/
│   ├── 01_create_schema.sql     # 建 schema 与表
│   ├── 02_import_data.sql       # 导入 9 个 CSV
│   ├── 03_constraints_views.sql # 外键、索引、分析视图
│   ├── 04_data_exploration.sql  # 数据探索与质量检查
│   ├── 06_factor_analysis.sql   # ★ 31 条归因查询（7 个部分）
│   └── 07_pbi_view.sql          # ★ BI 专用订单级宽表
├── python/
│   ├── stat_analysis.py         # 相关分析、效应量、卡方检验
│   ├── rigorous_model.py        # ★ OLS / Logit / 随机森林
│   └── output/                  # 8 张统计图 + 13 个结果 CSV
├── powerbi/
│   ├── olist_dashboard.pbix
│   ├── DAX_度量值与计算列.dax
│   └── screenshots/             # 6 页仪表盘截图
├── docs/
│   └── report.pdf               # 分析报告
└── .gitignore                   # 排除原始 CSV（120 MB）
```

7.3 关键代码片段

四段耗时拆解——整个分析的分诊环节，决定了后续所有分析方向：

SQL：四段耗时拆解

```
SELECT
  -- ① 下单 → 审核
  round(avg(EXTRACT(EPOCH FROM (order_approved_at - order_purchase_timestamp))
            / 86400)::numeric, 2) AS 下单到审核_天,
  -- ② 审核 → 交给物流（= 卖家备货时间）
  round(avg(EXTRACT(EPOCH FROM (order_delivered_carrier_date - order_approved_at))
            / 86400)::numeric, 2) AS 审核到发货_天,
  -- ③ 交给物流 → 客户签收（= 运输时间）
  round(avg(EXTRACT(EPOCH FROM (order_delivered_customer_date
            - order_delivered_carrier_date)) / 86400)::numeric, 2) AS 发货到签收_天,
  count(*) AS 样本数
FROM olist.orders
-- 过滤三个时间戳都非空：否则各列分母不同，四段加起来对不上全程
WHERE order_delivered_customer_date IS NOT NULL
  AND order_approved_at IS NOT NULL
  AND order_delivered_carrier_date IS NOT NULL;
```

手写 OLS 完整统计推断（不依赖 statsmodels，便于理解每一步）：

Python：手写 OLS 推断（系数/标准误/t 值/p 值/R^2）

```
def ols(y, X, names):
    """最小二乘 + 完整统计推断。X 为设计矩阵（不含常数项）。"""
    n = len(y)
    Xd = np.column_stack([np.ones(n), X])       # 加截距项
    beta, *_ = np.linalg.lstsq(Xd, y, rcond=None)  # β = (X'X)^-1 X'y
    resid = y - Xd @ beta
    k = Xd.shape[1]; dof = n - k
    sigma2 = resid @ resid / dof
    XtX_inv = np.linalg.pinv(Xd.T @ Xd)         # 伪逆，防共线性奇异
    se = np.sqrt(np.diag(XtX_inv) * sigma2)
    tval = beta / se
    pval = 2 * (1 - stats.t.cdf(np.abs(tval), dof))
    r2 = 1 - (resid @ resid) / ((y - y.mean()) ** 2).sum()
    adj_r2 = 1 - (1 - r2) * (n - 1) / dof
    return dict(beta=beta, se=se, t=tval, p=pval, r2=r2, adj_r2=adj_r2)
```

7.4 复现步骤

1. 准备环境

- 安装 PostgreSQL 18，创建数据库 analysis

- Python 3.11 + pip install pandas numpy scipy scikit-learn matplotlib seaborn sqlalchemy psycopg2-binary python-docx

2. 下载数据

- 从 Kaggle 下载 Olist Brazilian E-Commerce Public Dataset（9 个 CSV）
- 放到项目 data/ 目录（该目录已加入 .gitignore，不进仓库）

3. 建库导入

命令行导入

```
psql -h 127.0.0.1 -U postgres -d analysis -f sql/01_create_schema.sql
psql -h 127.0.0.1 -U postgres -d analysis -f sql/02_import_data.sql
psql -h 127.0.0.1 -U postgres -d analysis -f sql/03_constraints_views.sql
psql -h 127.0.0.1 -U postgres -d analysis -f sql/07_pbi_view.sql
```

4. 跑分析

运行分析脚本

```
python python/stat_analysis.py     # 相关分析 → 5 张图 + 7 个 CSV
python python/rigorous_model.py     # 多元建模 → 3 张图 + 6 个 CSV
```

5. 打开仪表盘

- 用 Power BI Desktop 打开 powerbi/olist_dashboard.pbix
- 数据源指向本地 PostgreSQL 的 analysis 库（连接信息见 DAX 文件头部）

附录

A.1 A. 31 条分析查询的结构

表 SQL 文件结构（全部逐条验证通过）

部分	内容	条数
第 0 部分	基础信息与差评率基线	3
第 1 部分	流程拆解（定位瓶颈）	3
第 2 部分	地理因素	4
第 3 部分	卖家因素（备货 + 违约）	5
第 4 部分	商品因素（品类/重量/件数）	4
第 5 部分	时间因素（趋势/旺季/异常）	5
第 6 部分	汇总对比：各因素影响权重	3
第 7 部分	数据质量与局限	4
合计	—	31

B.1 B. 关键数字速查

表 报告中出现的关键数字

数字	含义
99,441 / 1,550,922	订单数 / 总行数
14.63%	差评率基线（1-2 星占比）
12.56 天	平均全程配送时长
0.43 / 2.81 / 9.33 天	审核 / 备货 / 运输 三段耗时
74.23%	运输环节占全程比例
53.94% vs 9.18%	迟到 vs 准时 的差评率
52.77% vs 8.79%	已超期 vs 未超期 的差评率
23.69% vs 11.68%	超期发货 vs 按期发货 的差评率
14.07% vs 10.43%	跨州 vs 同州 的差评率
9.06%	卖家超期发货率
8.11%	迟到率
-1.41	「是否迟到」的 Cohen's d

0.1695 / 0.1518 / 0.744	OLS R^2 / Logit 伪 R^2 / RF AUC
93,047 / 10 维	建模样本 / 特征数

C.1 C. 数据来源与许可

数据来自 Olist 巴西电商平台公开数据集（Kaggle），采用 CC BY-NC-SA 4.0 许可。本仓库仅包含分析代码与结果，不含原始数据文件。数据集地址：https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

— 报告完 —